MARKETSENSE · CABINET DE CONSEIL EN DONNÉES

Construire la chaîne de données et analyser le portefeuille d'un assureur IARD

Boréal Assurances · auto et habitation · janvier 2020 à juin 2025

Dossier · M2 Data Engineering et Data Analyse

Teddy Sagdo (projet individuel)
Dépôt : `boreal-Sagdo`
19/10/2026

Sommaire

Note exécutive 3

Introduction 4

1. Architecture et ingestion 5

1.1 Architecture cible 5

1.2 Justification des outils 5

1.3 Ingestion des sources (pipeline/ingest.py) 6

1.4 Chargement incrémental et idempotence 7

2. Qualité des données et modélisation 9

2.1 Contrôles et quarantaine 9

2.2 Déduplication des clients 12

2.3 Modèle dimensionnel 12

2.4 Tests automatisés 13

3. Analyse technique du portefeuille 15

3.1 Indicateurs techniques : constats et actions 15

3.2 Décomposition de l'évolution du S/P 16

3.3 Rigueur statistique 17

4. Clients et gestion des sinistres 19

4.1 Cohortes et multi-détention 19

4.2 Valeur observée des clients 20

4.3 Délais de gestion des sinistres 20

4.4 Audits antifraude 21

5. Dashboard, exploitation et documentation 23

5.1 Tableau de bord 23

5.2 Orchestration et alertes 25

5.3 Documentation 25

5.4 Lignage d'un indicateur : le ratio S/P, de la source au graphique 25

6. Protection des données personnelles (RGPD) 27

6.1 Données personnelles présentes 27

6.2 Pseudonymisation et minimisation 27

6.3 Bases légales et finalités 28

6.4 Durées de conservation proposées 28

6.5 Droit à l'effacement dans chaque couche 28

Conclusion 29

Annexes 30

A. Origine des chiffres clés 30

Note exécutive

Objet : ce que disent les données de Boréal Assurances (2020 à juin 2025) · **De :** MarketSense

Les chiffres de cette note viennent de l'entrepôt de données livré, mis à jour automatiquement à chaque nouveau fichier. Ce sont les mêmes que ceux du tableau de bord.

Le ratio sinistres sur primes (S/P) compare ce que coûtent les sinistres (déjà payés ou encore provisionnés) aux primes encaissées sur la même période. À 50 %, il reste 50 € pour 100 € de primes, avant les frais.

Trois constats

1. L'habitation est sous-tarifée, surtout dans les zones à risque.

- **Produit :** le S/P de l'habitation est de 64 %, contre 38 % pour l'auto, hors un sinistre exceptionnel. Les sinistres sont aussi fréquents en habitation qu'en auto : c'est la prime qui est trop basse.
- **Zone 5 :** les sinistres sont deux fois plus fréquents qu'en zone 1, mais la prime n'y est que 32 % plus chère. Le S/P y atteint 92 %.
- **Tarifs :** la prime moyenne n'a pas bougé depuis 2020 (445 € puis 441 €).

2. Quelques gros sinistres font le résultat.

- **Un seul accident auto de 2023 a coûté 2,48 M€**, soit 22 % de tout ce qui a été payé en cinq ans et demi. À lui seul, il fait passer le S/P 2023 de 39 % à 92 %.
- **10 % des sinistres représentent 61 % des montants.**
- Hors ces gros dossiers, le S/P est stable, entre 39 et 58 % par an.

3. Le Web fidélise mal et le contrôle de la fraude intervient trop tard.

- **Fidélité :** chaque année, 14 % des contrats sont perdus dès la première échéance. Les clients venus du Web résilient 1,5 fois plus que ceux des agences (18,5 % contre 12 % par an).
- **Fraude :** 407 000 € ont été versés sur des dossiers *après* que l'audit a confirmé la fraude. Les audits portent surtout sur les gros dossiers, où la fraude se confirme rarement (6 %). Pour les sinistres déclarés plus de 30 jours après les faits, la fraude est confirmée une fois sur deux.

Trois décisions proposées

1. **Réviser le tarif habitation dès la prochaine échéance**, en commençant par les zones 4 et 5, et indexer chaque année toutes les primes.
2. **Protéger le résultat contre les sinistres graves :** souscrire une réassurance pour les sinistres de plus de 50 000 €, et suivre ces dossiers chaque mois.
3. **Revoir le processus antifraude :**
   - bloquer tout paiement dès qu'une fraude est confirmée, et réclamer les 407 000 € déjà versés ;
   - auditer en priorité les déclarations tardives et les sinistres survenus dans les 90 jours suivant la souscription, avant le premier paiement.

En complément : prévoir un contact avec les clients Web avant leur première échéance.

Limites

- **2025 n'est observée que sur six mois**, et 36 % de son coût est encore estimé (dossiers ouverts). Les sinistres survenus mais pas encore déclarés n'apparaissent pas. Les chiffres 2024 et 2025 sont donc des minima.
- **Les frais de gestion et de distribution ne sont pas connus.** Le seuil d'alerte du tableau de bord (S/P de 70 %) suppose des frais de 25 à 30 % des primes : il faut le confirmer avec la direction financière.
- **Les sources contiennent des défauts**, mesurés et corrigés ou écartés : 200 clients en double, 32 paiements livrés deux fois, 45 contrats incohérents. Les âges du CRM semblent faussés pour environ 700 clients.
- **Ces analyses décrivent le passé** : elles ne prévoient pas les résultats futurs.

Introduction

Contexte et mission

Boréal Assurances assure 20 264 contrats auto et habitation, et a enregistré 2 805 sinistres déclarés entre janvier 2020 et juin 2025.

Le problème. Ses données sont réparties entre cinq outils qui ne se parlent pas : CRM, gestion des contrats, gestion des sinistres, comptabilité (règlements) et antifraude. Le ratio sinistres sur primes diffère selon le service qui le calcule, et un même client peut apparaître plusieurs fois.

La demande. La directrice technique, Camille Roux, veut une source unique de vérité, mise à jour sans intervention manuelle, et un tableau de bord qui réponde à trois questions :

- où le portefeuille gagne ou perd de l'argent ;
- comment les clients se comportent dans la durée ;
- si les délais de gestion des sinistres sont tenus.

Mission de MarketSense.

1. Construire un entrepôt de données alimenté par un pipeline reproductible et testé.
2. L'exploiter pour une analyse descriptive et explicative du portefeuille. Aucun modèle prédictif n'est construit.
3. Restituer les résultats dans un tableau de bord branché sur l'entrepôt.

Démarche et organisation du dossier

Chapitre	Livrable	Question traitée
1	Architecture et ingestion	Comment charger les 68 fichiers sans intervention manuelle ni doublon ?
2	Qualité et modélisation	Quels défauts contiennent les sources, et quel modèle les rend exploitables ?
3	Analyse technique	Où le portefeuille gagne-t-il ou perd-il de l'argent, et pourquoi le ratio S/P évolue-t-il ?
4	Clients et sinistres	Les clients restent-ils, lesquels créent de la valeur, les délais et les audits sont-ils maîtrisés ?
5	Dashboard et exploitation	Comment la directrice et l'équipe data suivent-elles ces résultats au quotidien ?
6	RGPD	Quelles données personnelles l'entrepôt contient-il, et comment les protéger ?

La note exécutive, en tête du dossier, résume les constats et les décisions proposées pour une lectrice non technicienne.

Conventions

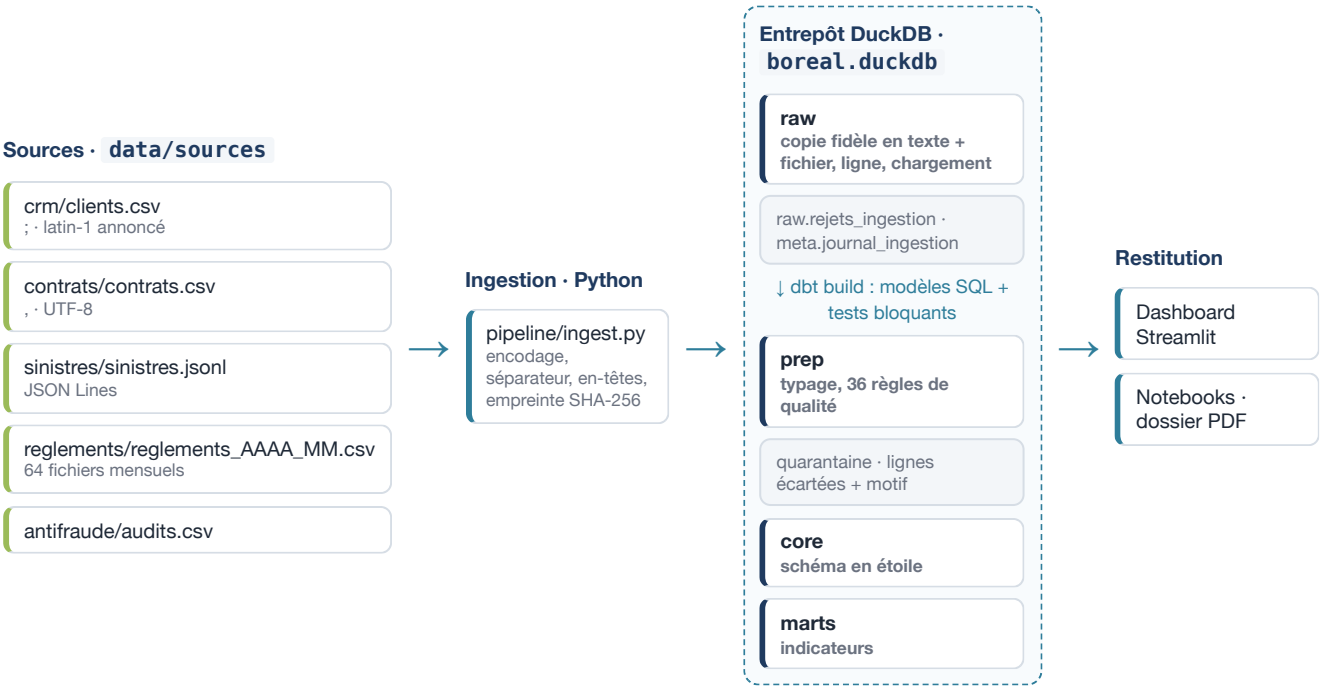
- **Origine des chiffres.** Tous les chiffres viennent de l'entrepôt DuckDB construit par `make run` : couche `marts` pour les analyses, `core` pour les contrôles. Chaque valeur est reproductible. L'annexe A indique, pour chaque chiffre clé, la requête, le modèle ou la cellule de notebook qui le produit.
- **Cohérence des restitutions.** Les indicateurs sont définis une seule fois, dans `analyse/indicateurs.py`, et partagés par les notebooks et le dashboard. Les chiffres du dossier, du dashboard et de l'entrepôt sont donc identiques.
- **Fréquences.** Elles sont toujours calculées par année-police (durée de couverture), jamais par nombre de contrats.
- **Périmètre temporel.** Les données s'arrêtent au 30/06/2025 : l'année 2025 est incomplète.

Contribution

Ce projet a été réalisé **individuellement** par Teddy Sagdo, auteur de l'ensemble des travaux : architecture, ingestion et orchestration, règles de qualité et modélisation, analyses statistiques, tableau de bord, documentation et dossier. Le dépôt se nomme `boreal-Sagdo` et ce dossier `SAGDO_Boreal.pdf`.

1. Architecture et ingestion

1.1 Architecture cible



Orchestration : `Makefile` + `pipeline/surveiller.py` (nouveau fichier → ingestion → dbt build → tests ; alerte en cas d'échec)

Couche	Schéma	Contenu	Outil
Brut	`raw`	Copie fidèle de chaque ligne source, toutes valeurs en texte, avec `_fichier_source`, `_numero_ligne`, `_id_chargement`, `_date_chargement`. Lignes illisibles dans `raw.rejets_ingestion`.	Python
Journal	`meta`	`journal_ingestion` : une ligne par fichier et par exécution.	Python
Préparation	`prep`	Typage (dates, nombres), nettoyage des blancs. Aucune ligne supprimée.	dbt (vues)
Cœur	`core`	Schéma en étoile : dimensions et faits au grain explicite, déduplication, quarantaine (livrable 2).	dbt (tables)
Marts	`marts`	Tables d'indicateurs prêtes pour le dashboard et les notebooks.	dbt (tables)

1.2 Justification des outils

Mesures prises sur la machine de développement (Apple M2, 8 Go de RAM) :

Mesure	Valeur
Volume des sources	2,6 Mo, 68 fichiers, 41 848 lignes de données
Taille de l'entrepôt après chargement	17 Mo, toutes couches comprises
Pipeline complet depuis un entrepôt vide (`make clean && make run`)	7,0 s : ingestion, 94 éléments dbt (modèles, seeds, snapshot, 56 tests) et publication des tests
Rechargement d'un mois (`make reload MOIS=2024_03`)	5,0 s, transformations et tests compris
Environnement Python installé	1,1 Go, 15 dépendances directes épinglées (dont le dashboard, les notebooks et la génération du dossier)

Outil	Rôle	Critère mesurable	Alternatives écartées
DuckDB 1.5	Entrepôt	*Volumétrie* : 3 Mo d'entrepôt, alors que DuckDB traite des dizaines de Go sur un portable. *Coût* : 0 €, aucun serveur. *Maintenance* : un fichier unique, installé par `pip`. *Compétences* : SQL standard avec fonctions analytiques (`QUALIFY`, fenêtres).	SQLite : pas de type date natif ni de lecture JSON, fonctions d'analyse limitées. PostgreSQL : un serveur à installer et administrer, sans gain à ce volume, et un obstacle pour exécuter le pipeline sur une machine vierge.
Python 3	Ingestion	Les sources mélangent 2 séparateurs, 2 encodages annoncés, 2 formats (CSV et JSON Lines) et 2 structures d'en-tête au sein des règlements. Une logique de détection, de traçabilité et de journalisation est plus robuste en Python qu'en SQL.	Ingestion 100 % SQL (`read_csv_auto`) : moins de contrôle sur les lignes illisibles et sur le journal.
dbt-core 1.12 + dbt-duckdb	Transformations et tests	Couvre directement plusieurs critères notés : un test en échec bloque les modèles en aval (`dbt build`), tests d'unicité et d'intégrité inclus, catalogue et lignage générés (`dbt docs`), modèles incrémentaux possibles. 94 éléments construits et testés en moins de 5 s.	Scripts SQL et runner maison : catalogue et lignage à écrire à la main.
Makefile	Orchestration	1 point d'entrée, 0 serveur. Toutes les opérations tiennent en une commande (`make run`, `make reload MOIS=…`).	Airflow, Prefect, Dagster : serveur ou compte cloud, une demi-journée à une journée de mise en place pour 68 fichiers et une exécution mensuelle.
Streamlit (livrable 5)	Dashboard	Lit directement les marts DuckDB, donc mêmes chiffres que l'entrepôt. Gratuit, déjà disponible en Python.	Power BI : indisponible sur macOS. Tableau : licence payante, pas de connecteur DuckDB dans la version gratuite.

Avec 100 fois plus de données (environ 260 Mo, 4 millions de lignes)

Composant	Ce qui changerait
Entrepôt	DuckDB tient toujours ce volume sur un poste. Le vrai seuil est ailleurs : DuckDB n'accepte qu'un processus en écriture. Avec plusieurs utilisateurs simultanés ou un dashboard publié, il faudrait passer à PostgreSQL ou à un entrepôt cloud (BigQuery, Snowflake). Les modèles dbt restent quasi identiques : seul l'adaptateur change.
Ingestion	Lecture en flux et en parallèle par fichier, avec `read_csv` de DuckDB, plutôt qu'en mémoire via pandas. Couche brute stockée en Parquet partitionné par mois.
Transformations	Les faits volumineux (règlements, exposition) passent en modèles dbt incrémentaux par mois au lieu d'une reconstruction complète. Les tests portent sur la dernière partition.
Orchestration	Avec des dizaines de sources et des dépendances entre elles, un orchestrateur dédié (Dagster ou Airflow) apporte reprises, parallélisme et historique des exécutions.
Dashboard	Les marts pré-agrégés suffisent. Il faudrait ajouter un cache et éviter tout calcul ligne à ligne dans l'application.

1.3 Ingestion des sources (`pipeline/ingest.py`)

Pour chaque fichier correspondant au motif d'une source (`pipeline/config.py`) :

1. **Empreinte** : SHA-256 du contenu, pour reconnaître un fichier déjà chargé.
2. **Encodage** : décodage en UTF-8, sinon en latin-1. L'encodage retenu est noté dans le journal.
3. **Séparateur** : détecté sur l'en-tête (`,` `;` tabulation `|`).
4. **Structure** : les noms de colonnes sont normalisés et comparés au contrat de la source. Les alias connus sont alignés (`montant_eur` → `montant`). Une colonne manquante ou inconnue fait échouer le fichier (`ECHEC`) : rien n'est chargé et le pipeline s'arrête.
5. **Lignes** : chaque ligne valide est copiée telle quelle, en texte, avec son fichier, son numéro de ligne, l'identifiant et la date du chargement. Une ligne vide, avec un mauvais nombre de champs ou un JSON invalide va dans `raw.rejets_ingestion` avec son motif. Rien n'est supprimé sans trace.

Constats à l'ingestion

Constat	Mesure	Traitement
Structure différente au sein des règlements	`reglements_2024_03.csv` : en-tête `montant_eur,paiement_id,sinistre_id,date_paiement` au lieu de `paiement_id,sinistre_id,date_paiement,montant`	Alignement des colonnes par leur nom (alias `montant_eur`), sans intervention manuelle
Séparateurs différents	`;` pour les clients, `,` ailleurs	Détection automatique
Encodage	`clients.csv` annoncé en latin-1, mais composé uniquement de caractères ASCII. Il est donc lu sans perte quel que soit le décodage.	Décodage UTF-8, repli automatique en latin-1
Paiements livrés deux fois	3 207 lignes brutes pour 3 175 `paiement_id` distincts : 32 paiements réapparaissent à l'identique (même sinistre, date et montant) dans le fichier du mois suivant	Conservés en brut, dédoublonnés en couche cœur (première livraison conservée, copie en quarantaine, règle REG_01)
Fichier postérieur à l'extraction	`reglements_2025_07.csv` existe alors que l'extraction date du 30/06/2025. Il contient 2 paiements datés de juin 2025.	Chargé tel quel. Traité comme règle de qualité au livrable 2.

Requête de contrôle des doublons :

```
SELECT count(*) AS lignes, count(DISTINCT paiement_id) AS paiements FROM raw.reglements;
-- 3207 | 3175
```

1.4 Chargement incrémental et idempotence

Journal d'ingestion (`meta.journal_ingestion`)

Colonne	Contenu
`id_execution`, `id_chargement`	Exécution du pipeline et chargement du fichier
`fichier`, `source`, `sha256`	Fichier traité et empreinte de son contenu
`encodage`, `separateur`	Format détecté
`lignes_lues`, `lignes_chargees`, `lignes_rejetees`	Volumes (lues = chargées + rejetées)
`debut`, `duree_s`	Horodatage et durée
`statut`, `message`	`CHARGE`, `RECHARGE`, `IGNORE`, `DOUBLON_LIVRAISON` ou `ECHEC`

`make journal` affiche la dernière exécution et l'état de chaque source.

Règles d'idempotence

Situation	Comportement	Statut
Fichier déjà chargé, contenu identique	Ignoré	`IGNORE`
Fichier connu, contenu modifié (livraison corrigée)	Ses anciennes lignes sont supprimées puis les nouvelles insérées, dans une seule transaction	`RECHARGE`
Rechargement demandé (`make reload MOIS=AAAA_MM`)	Même remplacement, forcé	`RECHARGE`
Même contenu livré sous un autre nom	Refusé	`DOUBLON_LIVRAISON`
Structure non conforme	Rien n'est chargé, code d'erreur, le pipeline s'arrête	`ECHEC`

Le chargement incrémental se fait à l'entrée de l'entrepôt : seuls les fichiers nouveaux ou modifiés sont lus et écrits en couche brute, ce qui joue le rôle du `NOT EXISTS` de l'énoncé.

Les couches `prep`, `core` et `marts` sont ensuite reconstruites intégralement par dbt à partir de la couche brute. Elles sont donc déterministes : à brut identique, le résultat est identique. Le dédoublonnage des paiements y garde la première livraison (`int_reglements`, règle REG_01).

Ce choix est mesuré. La reconstruction complète prend moins de 2 s pour 3 207 règlements. Elle garantit aussi qu'une correction en amont se propage partout, par exemple un contrat qui passe en quarantaine écarte les paiements de ses sinistres. Un modèle incrémental devrait gérer ces cascades à part. Pour un volume 100 fois plus grand, voir la section 2.

Que se passe-t-il au second passage ?

- **Couche brute :** chaque fichier a la même empreinte, il est donc `IGNORE` et aucune ligne n'est écrite. Le journal garde la trace du passage.
- **Cœur :** aucun paiement n'a de chargement plus récent que le dernier traitement, donc aucune ligne n'est recalculée.
- **Si l'on force le rejeu d'un mois :** les lignes de ce fichier sont remplacées par elles-mêmes et les paiements concernés sont recalculés à l'identique.

Comment le prouve-t-on ? Par `tests/test_ingestion.py`, exécuté par `make test` :

Test	Vérifie
`test_relancer_le_pipeline_ne_change_rien`	Second passage complet : 68 `IGNORE`, contenu du brut et du cœur strictement identique (empreinte de chaque ligne)
`test_rejouer_un_mois_ne_cree_aucun_doublon`	Rejeu forcé de `2024_03` : même nombre de lignes et même empreinte en brut et en cœur, `paiement_id` unique
`test_meme_mois_livre_deux_fois_sous_un_autre_nom_est_refuse`	Copie d'un mois sous un autre nom : `DOUBLON_LIVRAISON`, 0 ligne ajoutée
`test_fichier_corrige_remplace_la_version_precedente`	Livraison corrigée : l'ancienne version est entièrement remplacée
`test_structure_inconnue_bloque_le_fichier_sans_rien_charger`	Colonne inattendue : `ECHEC`, rien n'est chargé
`test_lignes_illisibles_vont_en_rejet_avec_motif`	Lignes vides ou incomplètes : rejetées avec motif, journal cohérent (3 lues = 1 chargée + 2 rejetées)

Les tests dbt bloquants complètent la preuve : `unique` et `not_null` sur `fct_reglement.paiement_id`, et une réconciliation brut = cœur + quarantaine (même nombre de lignes, même montant au centime). Voir qualite_modelisation.md.

2. Qualité des données et modélisation

Tous les chiffres de ce document sont produits par l'entrepôt (`make run`). La table `qualite.bilan_regles` les recalcule à chaque exécution.

2.1 Contrôles et quarantaine

Principe

Les contrôles sont écrits dans les modèles `prep.int_<source>` (dossier `dbt/models/intermediate/`). Chaque ligne y reçoit la liste des règles qu'elle viole (colonne `anomalies`). Le traitement de chaque règle est défini une seule fois, dans le catalogue `dbt/seeds/regles_qualite.csv` :

Traitement	Effet
EXCLURE	La ligne ne va pas dans le cœur. Elle est copiée dans `quarantaine.q_<source>` avec son fichier, son numéro de ligne et le libellé des règles violées (`motif`).
CORRIGER	La ligne va dans le cœur avec une valeur corrigée, et la règle reste visible dans `anomalies_signalees` .
SIGNALER	La ligne va dans le cœur sans modification, et la règle reste visible dans `anomalies_signalees` .

Aucune ligne n'est supprimée. Pour chaque source, lignes brutes = lignes du cœur + lignes en quarantaine. Un test bloquant le vérifie (§ 4).

Les exclusions se propagent d'une table à l'autre :

- un contrat en quarantaine écarte ses sinistres (SIN_04) ;
- un sinistre en quarantaine écarte ses paiements (REG_04) et son audit (AUD_03).

Le périmètre reste ainsi cohérent : aucun paiement n'est rattaché à un contrat absent du cœur.

Les 36 règles

La gravité exprime l'effet du défaut sur les indicateurs :

- **CRITIQUE** : la ligne est inexploitable (identifiant absent, référence cassée).
- **MAJEURE** : la ligne fausserait un indicateur (prime négative, doublon).
- **MINEURE** : la ligne reste exploitable, avec une réserve.

Les règles à volume nul restent actives : elles protègent les prochaines livraisons mensuelles.

Règle	Dimension	Description	Condition SQL (modèle)	Gravité	Volume	Traitement
AUD_01	unicité	Sinistre audité plusieurs fois	`a.rang_id > 1` (int_audits.sql)	MAJEURE	0 (0,0 %)	EXCLURE
AUD_02	complétude	Champ absent, illisible ou hors référentiel (sinistre, date, résultat 0/1)	`a.sinistre_id is null or a.date_audit is null or a.fraude_confirmee not in (0, 1) or a.fraude_confirmee is null or len(a.colonnes_illisibles) > 0` (int_audits.sql)	CRITIQUE	0 (0,0 %)	EXCLURE
AUD_03	cohérence entre tables	Sinistre audité inconnu ou en quarantaine	`s.sinistre_id is null or s.est_exclu` (int_audits.sql)	MAJEURE	2 (0,54 %)	EXCLURE
AUD_04	cohérence temporelle	Audit antérieur à la déclaration du sinistre	`a.date_audit < s.date_declaration` (int_audits.sql)	MINEURE	0 (0,0 %)	SIGNALER
CLI_01	complétude	Date de naissance absente	`date_naissance is null and not list_contains(colonnes_illisibles, 'date_naissance')` (int_clients.sql)	MINEURE	226 (1,49 %)	SIGNALER
CLI_02	validité	Date de naissance sentinelle 1890-01-01 (âge supérieur à 120 ans)	`date_naissance < date '2025-06-30' - interval 120 year` (int_clients.sql)	MINEURE	18 (0,12 %)	CORRIGER
CLI_03	validité	Date de naissance impossible : client encore mineur à la date d'extraction	`date_naissance + interval 18 year > date '2025-06-30'` (int_clients.sql)	MAJEURE	22 (0,14 %)	CORRIGER

Règle	Dimension	Description	Condition SQL (modèle)	Gravité	Volume	Traitement
CLI_04	unicité	Doublon de client (même empreinte d'e-mail qu'un client conservé)	`client_id_retenu <> client_id` (int_clients.sql)	MAJEURE	200 (1,32 %)	EXCLURE
CLI_05	unicité	Identifiant client présent plusieurs fois	`rang_id > 1` (int_clients.sql)	CRITIQUE	0 (0,0 %)	EXCLURE
CLI_06	validité	Valeur illisible ou hors référentiel (identifiant, date, région, CSP, consentement)	`client_id is null or email_hash is null or len(colonnes_illisibles) > 0 or region not in ('ARA','BFC','BRE','COR','CVL','GES','HDF','IDF','NAQ','NOR','OCC','PACA','PDL') or csp not in ('AGRICULTEUR','CADRE','EMPLOYE','ETUDIANT','INDEPENDANT','OUVRIER','RETRAITE','SANS_ACTIVITE') or consent_marketing not in (0, 1)` (int_clients.sql)	MAJEURE	0 (0,0 %)	EXCLURE
CLI_07	cohérence temporelle	Client mineur à la date de sa première souscription	`date_naissance + interval 18 year > date_premiere_souscription and date_naissance + interval 18 year <= date '2025-06-30'` (int_clients.sql)	MINEURE	700 (4,61 %)	SIGNALER
CTR_01	unicité	Identifiant contrat présent plusieurs fois	`rang_id > 1` (int_contrats.sql)	CRITIQUE	0 (0,0 %)	EXCLURE
CTR_02	complétude	Champ obligatoire absent, illisible ou hors référentiel (client, produit, dates, formule, canal, zone, franchise, prime)	`contrat_id is null or client_id is null or date_effet is null or prime_annuelle is null or franchise is null or len(colonnes_illisibles) > 0 or produit not in ('AUTO', 'HABITATION') or formule not in ('ESSENTIELLE', 'CONFORT', 'PREMIUM') or canal_distribution not in ('AGENT', 'COURTIER', 'WEB') or zone_risque not between 1 and 5` (int_contrats.sql)	CRITIQUE	0 (0,0 %)	EXCLURE
CTR_03	cohérence entre tables	Client du contrat inconnu du CRM ou en quarantaine	`client_id_retenu is null or client_retenu_exclu` (int_contrats.sql)	CRITIQUE	0 (0,0 %)	EXCLURE
CTR_04	validité	Prime annuelle nulle ou négative	`prime_annuelle <= 0` (int_contrats.sql)	MAJEURE	25 (0,12 %)	EXCLURE
CTR_05	cohérence temporelle	Date de résiliation antérieure à la date d'effet	`date_resiliation < date_effet` (int_contrats.sql)	MAJEURE	20 (0,1 %)	EXCLURE
CTR_06	cohérence temporelle	Contrat résilié le jour de son effet (couverture d'un jour)	`date_resiliation = date_effet` (int_contrats.sql)	MINEURE	6 (0,03 %)	SIGNALER
CTR_07	validité	Attribut incohérent avec le produit (auto sans puissance ou bonus-malus / habitation sans surface)	`(produit = 'AUTO' and (puissance_cv is null or bonus_malus is null)) or (produit = 'HABITATION' and surface_m2 is null)` (int_contrats.sql)	MINEURE	0 (0,0 %)	SIGNALER
CTR_08	cohérence temporelle	Date d'effet postérieure à la date d'extraction	`date_effet > date '2025-06-30'` (int_contrats.sql)	MAJEURE	0 (0,0 %)	EXCLURE
REG_01	unicité	Paiement déjà livré dans un fichier antérieur (copie écartée)	`paiement_id is not null and rang_livraison > 1` (int_reglements.sql)	MAJEURE	32 (1,0 %)	EXCLURE
REG_02	complétude	Champ obligatoire absent ou illisible (paiement, sinistre, date, montant)	`paiement_id is null or sinistre_id is null or date_paiement is null or montant is null or len(colonnes_illisibles) > 0` (int_reglements.sql)	CRITIQUE	0 (0,0 %)	EXCLURE
REG_03	cohérence entre tables	Sinistre du paiement inconnu	`sinistre_id is not null and not sinistre_connu` (int_reglements.sql)	CRITIQUE	0 (0,0 %)	EXCLURE
REG_04	cohérence entre tables	Sinistre du paiement en quarantaine	`sinistre_connu and sinistre_exclu` (int_reglements.sql)	MAJEURE	24 (0,75 %)	EXCLURE
REG_05	validité	Montant nul ou négatif	`montant <= 0` (int_reglements.sql)	MAJEURE	0 (0,0 %)	EXCLURE
REG_06	cohérence temporelle	Paiement antérieur à la survenance ou postérieur à l'extraction	`date_paiement < sinistre_date_survenance or date_paiement > date '2025-06-30'` (int_reglements.sql)	MAJEURE	0 (0,0 %)	EXCLURE
REG_07	cohérence temporelle	Ligne livrée dans un fichier postérieur à la date d'extraction	`mois_livraison > strftime(date '2025-06-30', '%Y_%m')` (int_reglements.sql)	MINEURE	2 (0,06 %)	SIGNALER

Règle	Dimension	Description	Condition SQL (modèle)	Gravité	Volume	Traitement
REG_08	cohérence	Paiement sur un sinistre rejeté ou sans suite	`sinistre_statut in ('REJETE', 'SANS_SUITE')` (int_reglements.sql)	MAJEURE	0 (0,0 %)	SIGNALER
SIN_01	unicité	Identifiant sinistre présent plusieurs fois	`rang_id > 1` (int_sinistres.sql)	CRITIQUE	0 (0,0 %)	EXCLURE
SIN_02	complétude	Champ obligatoire absent, illisible ou hors référentiel (contrat, dates, garantie, statut, réserve)	`sinistre_id is null or contrat_id is null or date_survenance is null or date_declaration is null or reserve_initiale is null or len(colonnes_illisibles) > 0 or statut not in ('OUVERT', 'CLOTURE', 'REJETE', 'SANS_SUITE')` (int_sinistres.sql)	CRITIQUE	0 (0,0 %)	EXCLURE
SIN_03	cohérence entre tables	Contrat du sinistre inconnu	`not contrat_connu` (int_sinistres.sql)	CRITIQUE	0 (0,0 %)	EXCLURE
SIN_04	cohérence entre tables	Contrat du sinistre en quarantaine	`contrat_connu and contrat_exclu` (int_sinistres.sql)	MAJEURE	5 (0,18 %)	EXCLURE
SIN_05	cohérence temporelle	Survenance hors de la période de couverture du contrat	`date_survenance < contrat_date_effet or date_survenance > coalesce(contrat_date_resiliation, date '2025-06-30') or date_survenance > date '2025-06-30'` (int_sinistres.sql)	MAJEURE	18 (0,64 %)	EXCLURE
SIN_06	cohérence temporelle	Déclaration antérieure à la survenance	`date_declaration < date_survenance` (int_sinistres.sql)	MINEURE	15 (0,53 %)	CORRIGER
SIN_07	cohérence entre tables	Garantie incompatible avec le produit du contrat	`contrat_connu and not garantie_compatible` (int_sinistres.sql)	MAJEURE	0 (0,0 %)	EXCLURE
SIN_08	validité	Réserve initiale atypique (supérieure à 1 million d'euros)	`reserve_initiale > 1000000` (int_sinistres.sql)	MINEURE	1 (0,04 %)	SIGNALER
SIN_09	cohérence	Sinistre rejeté ou sans suite avec une réserve positive	`statut in ('REJETE', 'SANS_SUITE') and reserve_initiale > 0` (int_sinistres.sql)	MINEURE	0 (0,0 %)	SIGNALER

Impact des exclusions

Source	Lignes brutes	En quarantaine	Montant écarté	Motif principal
Clients	15 200	200 (1,32 %)	aucun	Doublons (CLI_04), sans contrat
Contrats	20 264	45 (0,22 %)	7 562,83 € de primes annuelles	25 primes nulles ou négatives (–50 € ou 0 €), 20 résiliations avant l'effet
Sinistres	2 805	22 (0,78 %)	52 503,15 € de réserves initiales	18 survenances hors couverture, 4 sur un contrat écarté
Règlements	3 207	56 (1,75 %)	118 175,46 €	32 copies de livraison (73 150,42 €), 24 paiements de sinistres écartés (45 025,04 €)
Audits	372	2 (0,54 %)	aucun	Audits de sinistres écartés

Ce qu'il faut retenir :

- Sans le dédoublonnage des règlements, les montants payés seraient surestimés de 73 150,42 €, soit 0,65 % du total payé.
- Les exclusions de contrats et de sinistres pèsent moins de 0,8 % des volumes.

Point d'attention pour l'analyse : le sinistre 1129. C'est une collision auto de 2023. Sa réserve initiale est de 1 252 690,25 € et il a donné lieu à 2 475 974,67 € de règlements, soit **22 % de tous les montants payés** de 2020 à juin 2025.

- Ce n'est pas une erreur de saisie démontrable : la réserve et les paiements sont cohérents entre eux.
- Il est donc conservé et signalé (SIN_08, colonne `est_atypique`).
- Les analyses du livrable 3 présenteront le ratio sinistres sur primes avec et sans ce sinistre grave.

Défaut de la source non corrigé : âges au CRM. 700 clients auraient été mineurs (13 à 17 ans) à leur première souscription (CLI_07). Les dates de naissance s'accumulent juste avant le 30/06/2007, et 491 clients ont exactement 18 ans à la date d'extraction. Tout indique des âges plafonnés à 18 ans à la date d'extraction. La date n'est pas corrigée, mais la tranche d'âge est calculée à la date d'extraction pour ne créer aucun client mineur dans les analyses.

2.2 Déduplication des clients

Clé de rapprochement : l'empreinte d'e-mail (`email_hash`). C'est le seul identifiant personnel disponible : les données sont pseudonymisées, sans nom ni coordonnées.

Mesure :

- 200 empreintes apparaissent deux fois, soit 400 fiches.
- Le taux de doublons est de **200 / 15 200 = 1,32 %** des fiches.

Contrôle de la clé : pour les 200 paires, la date de naissance, la région, la CSP et le consentement sont identiques. La clé ne rapproche donc pas de personnes différentes.

```
SELECT count(*) AS paires,
       count(*) FILTER (WHERE n_dn = 1 AND n_region = 1 AND n_csp = 1 AND n_consent = 1) AS
attributs_identiques
FROM (SELECT email_hash, count(DISTINCT date_naissance) n_dn, count(DISTINCT region) n_region,
             count(DISTINCT csp) n_csp, count(DISTINCT consent_marketing) n_consent
      FROM prep.stg_clients GROUP BY email_hash HAVING count(*) > 1);
-- 200 | 200
```

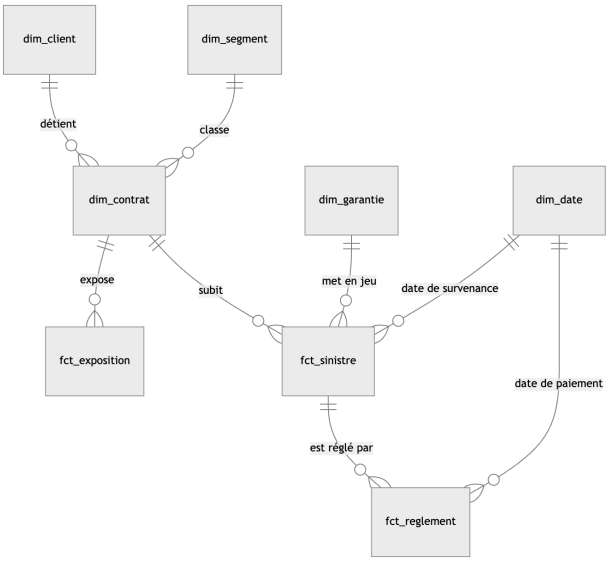
Règle de survie : parmi les fiches de même empreinte, on conserve celle qui porte des contrats, puis le plus petit identifiant.

- Ici, la fiche conservée est toujours l'identifiant ancien (33 à 14 988).
- Les doublons (identifiants 15 001 à 15 200) n'ont aucun contrat.

Contrats rattachés : la table `core.client_rapprochement` fait passer chaque identifiant du CRM vers l'identifiant conservé. Tout contrat est rattaché au survivant (`dim_contrat.client_id` = `client_id_retenu`). Dans cette livraison, aucun contrat ne portait un identifiant doublon. Si cela arrive dans une livraison future, le contrat est rattaché automatiquement sans être perdu.

Fiches écartées : les 200 fiches doublons vont dans `quarantaine.q_clients` avec le motif CLI_04.

2.3 Modèle dimensionnel



Grains

Table	Grain	Lignes	Mesures principales
`fct_exposition`	un contrat × une année civile	65 109	`jours_couverts` , `annees_police` , `prime_acquise` , `resilie_dans_annee`
`fct_sinistre`	un sinistre	2 783	`reserve_initiale` , `montant_paye` , `reserve_restante` , `charge_totale` , délais, audit

Table	Grain	Lignes	Mesures principales
`fct_reglement`	un paiement	3 151	`montant`
`dim_contrat`	un contrat	20 219	attributs de souscription, `date_fin_observation`
`dim_client`	un client conservé	15 000	âge, région, CSP, consentement
`dim_segment`	produit × zone × formule × canal	90	
`dim_garantie`	produit × garantie	8	
`dim_date`	un jour (2019 à 2025)	2 557	

Pourquoi l'exposition au grain contrat × année ? L'énoncé impose une fréquence par année-police. Ce grain permet de calculer directement :

- la fréquence d'une année : sinistres survenus dans l'année / somme des `annees_police` de l'année ;
- les primes acquises de l'année, au prorata des jours couverts ;
- le taux de résiliation par année.

Règles de calcul de l'exposition :

- Couverture du jour d'effet au jour de résiliation, bornes incluses.
- Pour les contrats en cours, la couverture est arrêtée au 30/06/2025.
- Années-police = jours couverts / 365. Prime acquise = prime annuelle × jours couverts / 365.
- 2025 n'est observée que sur six mois (`annee_complete = false`).

```
-- Exposition et primes acquises par année
SELECT annee, round(sum(annees_police), 1) AS annees_police, round(sum(prime_acquise)) AS
primes_acquises
FROM core.fct_exposition GROUP BY annee ORDER BY annee;
-- 2020 : 1 857,2 | 2021 : 5 154,6 | 2022 : 8 075,9 | 2023 : 10 555,2 | 2024 : 12 681,8 | 2025
(6 mois) : 6 890,4
```

Ce que contiennent les faits sinistre :

- *payé* : les règlements reçus (`montant_paye`) ;
- *réserve* : la réserve restante des dossiers ouverts (`reserve_restante`) ;
- *sans suite* : les dossiers rejetés ou classés (`est_sans_suite`).

Les sources ne contiennent pas de date de clôture. Pour un dossier clôturé, la date du dernier règlement en tient lieu (`delai_cloture_j`).

Gestion de l'historique

Dimension	Type	Justification
`dim_client`	Type 1 dans le cœur, type 2 dans `snapshots.snap_clients`	Le CRM ne livre qu'un instantané : aucun historique n'existe dans les sources. Le snapshot dbt (stratégie `check` sur région, CSP, consentement, date de naissance) enregistre une nouvelle version à chaque changement lors des livraisons mensuelles suivantes, avec ses dates de validité. Les analyses utilisent la valeur courante.
`dim_contrat`	Type 0	Les attributs (formule, zone, prime, franchise) sont ceux de la souscription. Une modification de contrat serait un nouvel avenant, absent des sources.
`dim_segment` , `dim_garantie`	Type 0	Ce sont des référentiels.

2.4 Tests automatisés

Comment ils s'exécutent :

- `make run` lance `dbt build` , qui exécute chaque test juste après le modèle testé. Un test en échec interrompt la construction des modèles qui en dépendent.

- `make test` relance en plus les tests pytest du livrable 1.

État actuel (version livrée) : 94 éléments dbt, dont 56 tests (les marts des livrables 3 à 5 en ajoutent 8), et 17 tests pytest, tous au vert.

Test	Type	Vérifie
`unique` + `not_null` sur les clés de `dim_client`, `dim_contrat`, `dim_segment`, `dim_garantie`, `dim_date`, `fct_exposition`, `fct_sinistre`, `fct_reglement`, `client_rapprochement`	générique	Unicité des clés
`relationships` : contrat → client et segment, exposition → contrat, sinistre → contrat et garantie, règlement → sinistre et date, rapprochement → client	générique	Intégrité référentielle du schéma en étoile
`accepted_values` sur produit, statut, tranche d'âge, traitement	générique	Validité des référentiels
`unique` sur `dim_client.email_hash`	générique	Aucun doublon client résiduel
`reconciliation_reglements_brut_coeur`	singulier	Lignes et montant des règlements : brut = cœur + quarantaine, au centime
`reconciliation_sources_coeur_quarantaine`	singulier	Pour clients, contrats, sinistres et audits : brut = cœur + quarantaine
`exposition_toujours_positive`	singulier	Chaque ligne d'exposition couvre entre 1 et 366 jours, avec une prime acquise positive
`exposition_egale_duree_contrat`	singulier	La somme des expositions annuelles d'un contrat égale sa durée de couverture
`sinistre_dans_periode_couverture`	singulier	Tout sinistre du cœur survient pendant la couverture de son contrat
`montant_paye_egal_reglements`	singulier	Le payé d'un sinistre égale la somme de ses règlements
`quarantaine_avec_motif`	singulier	Toute ligne écartée a un motif et un fichier d'origine
`ingestion_sans_echec`	singulier	Aucun fichier source n'est en échec dans le journal
`tests/test_ingestion.py` (6 tests)	pytest	Idempotence et rechargement (livrable 1)

3. Analyse technique du portefeuille

Le détail des calculs, tableaux, tests et graphiques est dans le notebook notebooks/L3_analyse_technique.ipynb, exécuté sur l'entrepôt (`make notebooks`). Ce document en reprend les résultats.

Sources et définitions

D'où viennent les chiffres :

- Le notebook lit uniquement les marts dbt :
  - `marts.mart_technique` : mesures additives par année, produit, zone, formule, canal, région et tranche d'âge ;
  - `marts.mart_contrat_annee` : grain contrat × année ;
  - `marts.mart_sinistres` : grain sinistre.
- Un test dbt bloquant (`mart_technique_reconcilie_coeur`) vérifie que les marts restituent les totaux du cœur : primes acquises, années-police, charge et nombre de sinistres.
- Les formules sont codées une seule fois dans `analyse/indicateurs.py` , que le dashboard réutilisera.

Indicateur	Définition
Fréquence	Sinistres avec suite / années-police
Coût moyen	Charge (payé + réserve restante) / sinistres avec suite
Prime moyenne	Primes acquises / années-police
S/P	Charge / primes acquises
Taux de résiliation	Résiliations / années-police

Les sinistres sont rattachés à leur année de survenance. Les sinistres rejetés ou classés sans suite (838, soit 30 % des déclarations) sont comptés à part.

Ensemble du portefeuille (2020 à juin 2025) : 45 215 années-police et 20,0 M€ de primes acquises.

Indicateur	Valeur	IC 95 %
Fréquence	4,30 %	4,11 – 4,50
Coût moyen	6 020 €	4 418 – 8 846
Prime moyenne	442 €	439 – 446
S/P	58,5 %	42,7 – 86,1
S/P hors sinistre atypique	46,2 %	41,6 – 51,2
Taux de résiliation	14,5 %	14,2 – 14,9

3.1 Indicateurs techniques : constats et actions

Axe	Constat	Action
Produit	L'habitation a un S/P de 63,8 % (IC 55 – 74), contre 38,0 % (IC 33 – 44) pour l'auto hors sinistre atypique. La fréquence est voisine (4,2 % et 4,4 %).	Commencer la revue tarifaire par l'habitation.
Zone	En habitation, la fréquence double de la zone 1 (2,96 %) à la zone 5 (5,77 %), mais la prime n'augmente que de 32 %. Le S/P de la zone 5 atteint 92,5 %.	Relever le tarif habitation des zones 4 et 5.
Formule	Auto Essentielle : 396 déclarations sans suite pour 133 sinistres indemnisés. Habitation Essentielle : S/P de 75,5 % et résiliation de 17,1 %.	Revoir la prime de l'Essentielle habitation et expliquer les exclusions de garantie.

Axe	Constat	Action
Canal	La fréquence et la prime ne varient pas selon le canal. La résiliation atteint 18,7 % (auto) et 18,2 % (habitation) sur le Web, contre environ 12 % en agence ou en courtage.	Lancer un plan de fidélisation des souscripteurs Web.
Âge	Les 18-25 ans ont la plus forte fréquence auto (7,41 %), mais leur surprime (825 €) maintient leur S/P à 40,8 %.	Ne pas modifier le tarif auto par âge ; surveiller l'habitation des 36-50 ans (S/P de 69,0 %).
Garanties	L'Essentielle ne couvre pas la collision, le bris de glace et le vol en auto, ni la tempête en habitation : 474 dossiers rejetés à 100 %.	Rappeler ces exclusions dans les documents et lors de la déclaration.

Payé, réserves et sans suite :

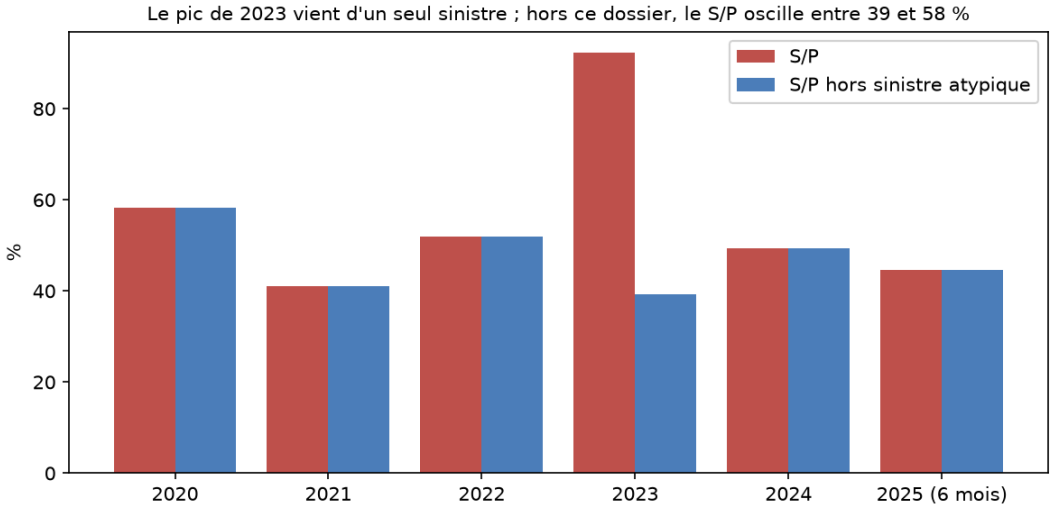
- Les réserves représentent 36,2 % de la charge 2025 et 1,5 % de celle de 2024. Avant 2024, tous les dossiers sont clôturés.
- 2025 doit donc être présentée comme provisoire.

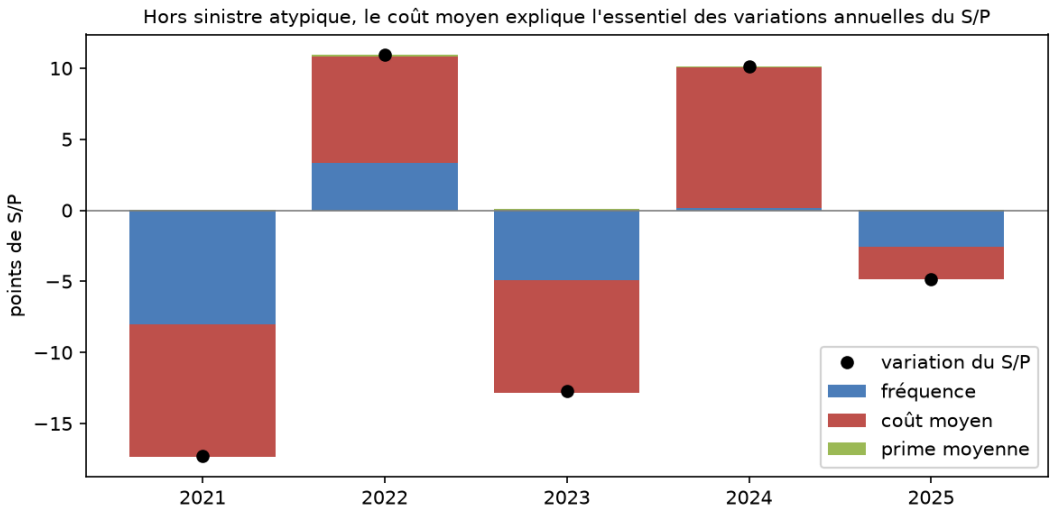
3.2 Décomposition de l'évolution du S/P

Méthode. S/P = fréquence × coût moyen / prime moyenne. La variation est décomposée en effets exactement additifs par la méthode LMDI. Le volume d'années-police joue autant sur la charge que sur les primes, donc son effet sur le ratio est nul. Il est chiffré sur la charge.

Sinistre atypique. Le sinistre 1129 est une collision auto de 2023 qui a coûté 2,48 M€, soit 22 % de toute la charge. Il est présenté à part.

Année	S/P	S/P hors atypique	Variation hors atypique (pts)	Effet fréquence	Effet coût moyen	Effet prime moyenne
2020	58,3 %	58,3 %				
2021	41,0 %	41,0 %	−17,3	−8,0	−9,3	0,0
2022	52,0 %	52,0 %	+11,0	+3,3	+7,5	+0,2
2023	92,4 %	39,3 %	−12,7	−4,9	−7,9	+0,1
2024	49,4 %	49,4 %	+10,1	+0,2	+9,9	0,0
2025 (6 mois)	44,5 %	44,5 %	−4,8	−2,6	−2,3	0,0





Constats :

1. **Le coût moyen fait le S/P.** Le sinistre 1129 explique à lui seul +47,8 points en 2023 et −43,3 en 2024. Hors ce dossier, l'effet coût moyen est de 7 à 10 points par an, en hausse ou en baisse, de 2021 à 2024.
2. **La fréquence est stable**, entre 4,0 et 4,7 % depuis 2021.
3. **La prime moyenne est figée** (445 € en 2020, 441 € en 2025) : aucune hausse tarifaire n'a compensé l'évolution des coûts.
4. **Le volume a fait croître la charge** de 0,6 à 0,8 M€ par an de 2021 à 2024, sans effet sur le ratio.

Segments qui contribuent le plus (produit × zone, hors sinistre atypique) :

- **Dégradations :**
  - auto zone 1 en 2022 (+8,3 points) ;
  - auto zone 3 en 2024 (+3,6) ;
  - habitation zone 5 en 2025 (+8,6), à cause d'un incendie encore ouvert de 110 671 €.
- **Améliorations :** auto zone 1 en 2021 (−12,3) et en 2023 (−7,3).

L'habitation zone 5 est le seul segment à la fois structurellement cher et contributeur récent.

Années incomplètes :

- **2020 :** le portefeuille démarre le 01/01/2020, avec une exposition faible (1 857 années-police).
- **2025 :** seuls six mois sont observés, et 36 % de la charge est en réserve.
- **2024 :** quelques dossiers restent ouverts.
- **Sinistres non encore déclarés :** ils n'apparaissent pas au 30/06/2025. Les S/P 2024 et 2025 sont donc des minima.

3.3 Rigueur statistique

Intervalles de confiance à 95 %.

Indicateur	Méthode	Pourquoi
Fréquence, résiliation	Intervalle exact de Poisson (Garwood)	Événements rapportés à une exposition
Coût moyen	Bootstrap percentile sur les sinistres	Coûts très asymétriques
S/P, prime moyenne	Bootstrap percentile sur les contrats, 5 000 tirages	Ratio de sommes, avec plusieurs années par contrat

Indicateur	Auto	Habitation
Fréquence	4,38 % (4,12 – 4,66)	4,21 % (3,95 – 4,49)
Coût moyen	7 544 € (4 625 – 12 992)	4 343 € (3 804 – 4 944)
Prime moyenne	589 € (586 – 593)	287 € (285 – 289)
S/P	56,1 % (34,0 – 95,8)	63,8 % (55,2 – 73,7)

Indicateur	Auto	Habitation
S/P hors atypique	38,0 % (32,8 – 44,2)	63,8 % (55,2 – 73,7)
Résiliation	14,7 % (14,2 – 15,2)	14,4 % (13,9 – 14,9)

Tests.

Comparaison	Test et justification	Résultat
Fréquence habitation, zone 5 contre zone 1	Test E de Poisson (Krishnamoorthy-Thomson) : comptages sur des expositions inégales	5,77 % contre 2,96 %, rapport 1,95, **$p = 1{,}6 \cdot 10^{-6}$** : écart significatif
Coût d'un sinistre auto, agence contre Web	Mann-Whitney : distributions asymétriques, sans hypothèse de normalité	Moyennes 11 273 € et 4 828 €, mais médianes 2 278 € et 2 382 €, **$p = 0{,}44$** : pas de différence. L'écart des moyennes vient d'un seul dossier.
Résiliation, Web contre agence (complément)	Test E de Poisson	18,5 % contre 12,0 %, rapport 1,54, **$p < 10^{-10}$**

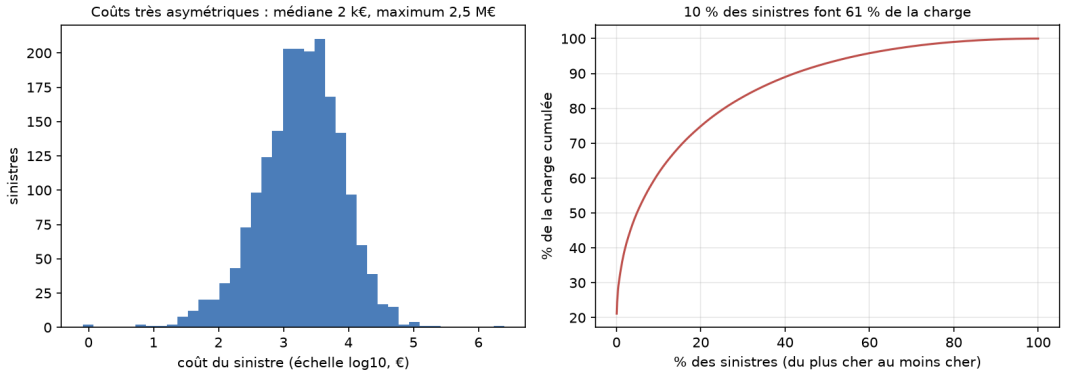
Queue de distribution des coûts (1 945 sinistres avec suite).

Médiane	75 %	90 %	95 %	99 %	99,9 %	Maximum	Moyenne
1 997 €	5 013 €	10 829 €	16 541 €	43 196 €	178 188 €	2 475 975 €	6 020 €

Concentration de la charge :

- les 2 dossiers les plus chers (0,1 %) font 22,9 % de la charge ;
- les 1 % les plus chers en font 33,4 % ;
- les 5 % les plus chers en font 50,4 % ;
- les 10 % les plus chers en font 61,4 %.

Coût selon la garantie : l'incendie est la garantie la plus coûteuse (médiane 9 300 €), devant la RC auto (3 885 €). Le bris de glace est la moins coûteuse (294 €).



Action : suivre à part les sinistres de plus de 50 000 € et étudier une réassurance en excédent de sinistre. Un seul dossier a coûté 12 % des primes acquises de toute la période.

4. Clients et gestion des sinistres

Le détail des calculs est dans le notebook notebooks/L4_clients_sinistres.ipynb, exécuté sur les marts de l'entrepôt :

- `mart_retention_contrats` et `mart_retention_clients` pour les cohortes ;
- `mart_clients` pour la valeur client ;
- `mart_sinistres` pour les délais et les audits.

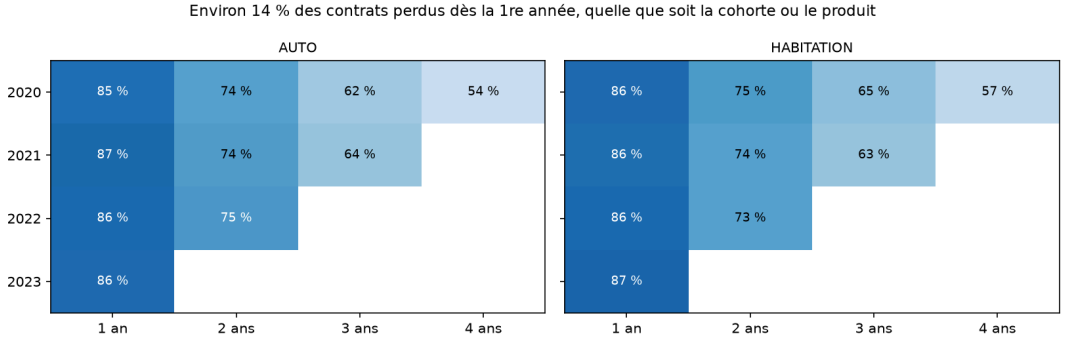
Un test dbt bloquant (`mart_clients_reconcilie_coeur`) vérifie que la valeur client totale égale les primes acquises moins les sinistres payés du cœur. Chaque chiffre ci-dessous précise sa population.

4.1 Cohortes et multi-détention

Rétention des contrats par cohorte de souscription.

Un contrat est retenu à *n* ans s'il n'est pas résilié à son *n*-ième anniversaire. **Population :** contrats valides. Seules les cellules entièrement observables sont présentées, c'est-à-dire celles dont tous les contrats ont atteint l'anniversaire avant le 30/06/2025. Les cohortes 2024 et 2025 n'ont donc encore aucune cellule complète.

Produit	Cohorte	Contrats	1 an	2 ans	3 ans	4 ans
Auto	2020	2 061	85,2 %	73,5 %	62,2 %	53,9 %
Auto	2021	1 928	86,8 %	74,4 %	63,6 %	
Auto	2022	2 004	86,5 %	75,3 %		
Auto	2023	1 905	85,8 %			
Habitation	2020	1 861	85,8 %	75,0 %	65,0 %	56,6 %
Habitation	2021	1 847	85,6 %	73,7 %	63,3 %	
Habitation	2022	1 935	86,4 %	73,3 %		
Habitation	2023	1 848	87,0 %			



La rétention est stable d'une cohorte à l'autre et entre produits. Environ 14 % des contrats sont perdus dès la première année, et aucune cohorte récente ne se dégrade.

Multi-détention. 5 242 clients sur 14 977 (35,0 %) ont détenu un contrat auto et un contrat habitation entre 2020 et juin 2025.

Les multi-détenteurs sont-ils plus fidèles ? La comparaison directe serait biaisée : un client qui reste longtemps a plus d'occasions de souscrire un second produit. On utilise donc deux mesures qui ne regardent pas le futur.

Mesure	Population	Résultat
Rétention à 1 an des contrats selon que le client détenait déjà l'autre produit à la souscription	Contrats des cellules complètes	87,0 % (n = 2 537) contre 86,0 % (n = 12 852), khi-deux p = 0,21 : **pas de différence**
Part des clients actifs au 1er janvier encore clients un an plus tard (2021 à 2024)	Clients actifs à la date de référence	2 produits : 97,8 à 99,5 % ; 1 produit : 86,8 à 88,3 %
Fidélité mécanique attendue pour 2 produits, soit $1 - (1 - p)^2$ avec p la rétention mono-produit	Même population	98,3 à 98,6 %, identique au taux observé

Conclusion. Le multi-équipement retient le client **par l'addition des contrats** : il faut en résilier deux pour partir. Il ne rend pas chaque contrat plus fidèle. La vente croisée réduit donc la perte de clients, mais elle ne remplace pas une action sur la

première échéance.

4.2 Valeur observée des clients

Définition. Valeur observée = primes acquises − sinistres payés, du 01/01/2020 au 30/06/2025. Les réserves ouvertes ne sont pas déduites, et les frais de gestion et de distribution ne sont pas connus.

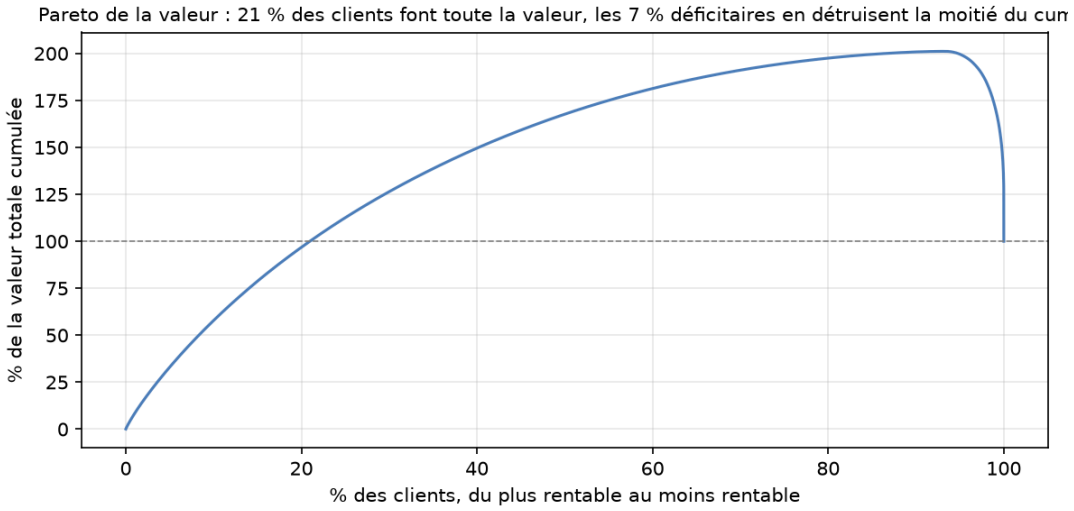
Population. 14 977 clients ayant au moins un contrat valide.

Résultats :

- **Valeur totale :** 8,82 M€, avec une médiane de 933 € par client.
- **Clients positifs :** ils créent 17,75 M€.
- **Clients déficitaires :** 1 001 clients (6,7 %) détruisent 8,92 M€.

Concentration (courbe de Pareto) :

Clients les plus rentables	1 %	5 %	10 %	20 %	50 %
Part de la valeur totale	8,3 %	33,0 %	57,8 %	96,8 %	167,7 %



Profils (déciles de valeur) :

	10 % les plus rentables	Ensemble	10 % les moins rentables
Valeur moyenne	3 408 €	589 €	−5 939 €
Années-police moyennes	6,1	3,0	2,5
Sinistres avec suite par client	0,08	0,13	0,78
Multi-détenteurs	68 %	35 %	32 %
Encore clients au 30/06/2025	95 %		55 %
Clients « habitation seule »	0,1 %	30,6 %	42,2 %
18-25 ans	15,1 %	8,6 %	9,2 %

Ce qui départage : l'ancienneté, l'absence de sinistre et le multi-équipement.

Ce qui ne départage pas : la CSP, la région et l'âge (hors 18-25 ans) ont des répartitions quasi identiques dans les deux groupes.

Action : fidéliser et multi-équiper les clients anciens et sans sinistre. Ne pas segmenter le marketing sur la CSP ou la région.

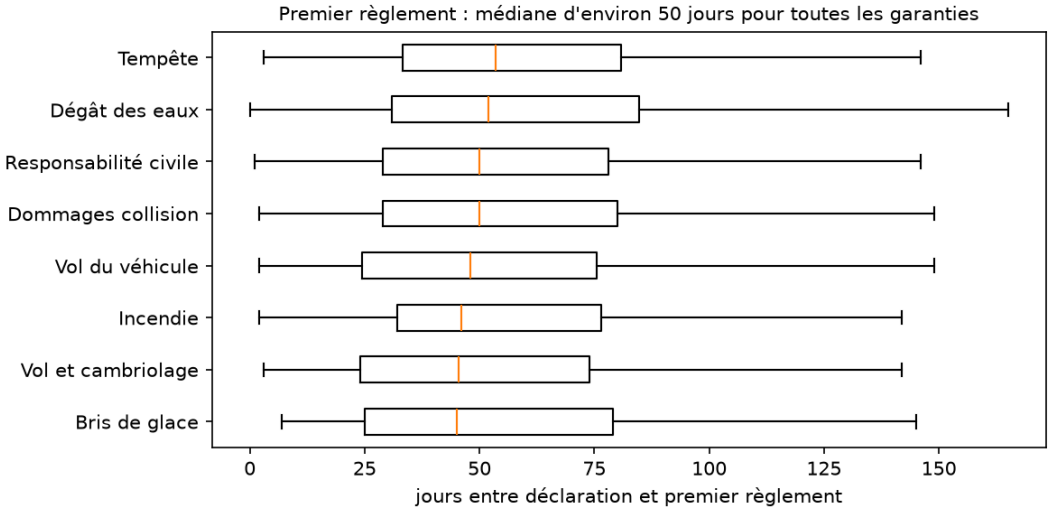
4.3 Délais de gestion des sinistres

Définitions et populations :

Délai	Définition	Population
Déclaration	Survenance → déclaration	Sinistres valides, hors 15 déclarations antérieures à la survenance
Premier règlement	Déclaration → premier paiement	Les 1 845 sinistres payés
Clôture	Déclaration → dernier paiement	Sinistres au statut CLOTURE. Les sources n'ont pas de date de clôture : le dernier paiement en tient lieu

Résultats par garantie (médiane, avec le 90e centile entre parenthèses, en jours) :

Garantie	Déclaration	Premier règlement	Clôture
Bris de glace	6 (19)	45 (106)	92 (243)
Incendie	6 (23)	46 (133)	76 (189)
Vol et cambriolage	6 (25)	46 (103)	71 (204)
Vol du véhicule	5 (24)	48 (113)	72 (201)
Dommages collision	5 (20)	50 (118)	80 (209)
Responsabilité civile	5 (18)	50 (109)	88 (201)
Dégât des eaux	5 (19)	52 (117)	88 (223)
Tempête	4 (17)	54 (139)	84 (221)



Part des dossiers payés réglés sous un délai donné :

≤ 30 j	≤ 60 j	≤ 90 j	≤ 180 j
27,1 %	61,5 %	81,0 %	98,3 %

Lecture.

- Les assurés déclarent vite.
- Le premier règlement prend environ 50 jours quelle que soit la garantie. Le délai dépend donc du processus de gestion plutôt que de la complexité du dossier.

Action : les sources ne contiennent aucun engagement de délai. Fixer un objectif de premier règlement, par exemple 60 jours, aujourd'hui atteint pour 61,5 % des dossiers, et le suivre dans le dashboard.

4.4 Audits antifraude

Population. Les audits ne portent que sur les dossiers contrôlés : 370 audits valides sur 2 783 sinistres (13,3 %). 37 fraudes ont été confirmées, soit un taux de confirmation de **10,0 % (IC 95 % 7,1 – 13,5) parmi les dossiers audités**. Ce taux ne vaut pas pour le portefeuille : les dossiers ont été choisis, pas tirés au hasard.

Taux de confirmation selon les critères disponibles (population : dossiers audités) :

Critère	Part auditée	Fraude confirmée parmi les audités
Réserve > 10 k€	57,7 %	5,5 %
Réserve nulle	2,4 %	20,0 %
Déclaration > 30 jours après la survenance	46,0 %	**55,2 %** (32 sur 58)
Déclaration ≤ 7 jours	11,4 %	0,0 % (0 sur 200)
Sinistre < 90 jours après la souscription	16,6 %	**20,8 %**
Sinistre ≥ 90 jours après la souscription	12,9 %	8,2 %
Bris de glace	3,9 %	30,8 %
Vol du véhicule	11,4 %	26,3 %
Responsabilité civile	23,6 %	1,9 %
Incendie	45,4 %	8,2 %

Tests exacts de Fisher, sur les dossiers audités :

- déclaration tardive : rapport de cotes 75,6, $p = 4{,}5 \cdot 10^{-25}$;
- contrat de moins de 90 jours : rapport de cotes 2,9, $p = 0{,}011$.

Lecture. La sélection actuelle vise les gros montants et l'incendie ou la RC, où la fraude se confirme peu. La fraude se concentre ailleurs : sur les déclarations tardives, les contrats récents, le vol et le bris de glace.

Intérêt au regard des montants :

	Dossiers	Charge	Payé	Payé avant l'audit	Payé après l'audit
Tous les audits	370	6 520 414 €	6 415 578 €	3 964 618 €	2 450 960 €
Fraudes confirmées	37	506 127 €	487 280 €	80 703 €	**406 577 €**

Constats :

- Les fraudes confirmées ont été payées pour l'essentiel **après** la date d'audit, et 30 d'entre elles sont au statut « clôturé » et non « rejeté ».
- Les audits interviennent 53 jours en médiane après la déclaration, soit après le premier règlement (environ 50 jours).
- 68 déclarations tardives restent non auditées, pour une charge de 126 684 €.

Actions :

1. Suspendre les paiements dès qu'une fraude est confirmée, et engager le recouvrement des 406 577 € versés après confirmation.
2. Réorienter la sélection des audits vers les déclarations tardives et les sinistres survenus dans les 90 jours suivant la souscription.
3. Auditer avant le premier règlement.

Limite : les sources ne disent pas si un recouvrement a eu lieu en dehors de ces données.

5. Dashboard, exploitation et documentation

5.1 Tableau de bord

Le tableau de bord (`dashboard/app.py` , lancé par `make dashboard`) est une application Streamlit de quatre pages. Elle lit **uniquement les tables `marts`** de l'entrepôt et les définitions de `analyse/indicateurs.py` : ses chiffres sont ceux du dossier.

Page	Contenu
Portefeuille	Primes acquises, contrats actifs, fréquence, coût moyen, S/P, taux de résiliation ; évolution mensuelle comparée à la même période de l'année précédente ; alerte visuelle au-delà du seuil
Technique et clients	S/P par zone, formule, canal et âge ; décomposition de l'évolution du S/P ; matrice de rétention par cohorte ; concentration de la valeur client
Exploitation	Dernier chargement par source, lignes écartées par règle, résultats des tests, fraîcheur des données, délais de gestion des sinistres par garantie
Définitions	Définition de chaque indicateur, seuil d'alerte et règles de rattachement temporel

Interactions.

- **Filtres croisés :** cinq, sur la période, le produit, la région, le canal et la zone de risque. Une option exclut le sinistre atypique de 2,48 M€.
- **Infobulles :** chaque barre ou point affiche le détail (fréquence, coût moyen, prime moyenne, années-police).
- **Titres actionnables :** chaque graphique a un titre qui énonce le constat et l'action. Les titres des graphiques par segment sont recalculés selon les filtres : ils nomment le segment au S/P le plus élevé de la sélection.

Seuil d'alerte du S/P : 70 %. Les frais de gestion et d'acquisition d'un assureur IARD représentent couramment 25 à 30 % des primes. Au-delà d'un S/P de 70 %, le ratio combiné approche ou dépasse 100 % et l'activité perd de l'argent. C'est une hypothèse, à remplacer par le taux de frais réel de Boréal.

Pour repère, le S/P hors sinistre atypique est de 46 % (IC 95 % : 42 à 51 %). Sur l'habitation en zone 5, le S/P du premier semestre 2025 atteint 262 % et déclenche l'alerte, à cause d'un incendie encore ouvert.

Performance. Les marts pèsent au plus 23 329 lignes. Un test automatique (`tests/test_dashboard.py`) exécute chacune des quatre pages : sans erreur, elles s'affichent toutes ensemble en environ 3 secondes, sous l'exigence de 5 secondes par page.

Portefeuille

Indicateurs 2025, janvier à juin, comparés aux mêmes mois de 2024. Les sinistres sont rattachés à leur mois de survenance ; les montants récents incluent des réserves.

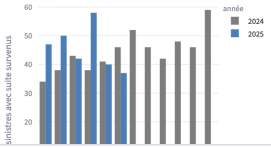
Primes acquises	Contrats actifs (fin de période)	Fréquence annualisée
3 041 390 €	13 645	4,0 %
↑ +375 456 €	↑ +1 018	↑ 0,00 pt

Coût moyen	S/P	Taux de résiliation annualisé
4 943 €	44,5 %	14,0 %
↓ -1 087 €	↓ -9,8 pt	↑ 0,0 pt

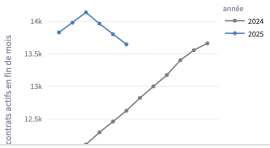
Le S/P cumulé 2025 est en dessous de celui de 2024 à période égale (44,5 %)



Sinistres par mois de survenance : comparer N à N-1 mois



Contrats actifs en fin de mois : le portefeuille croît-il encc

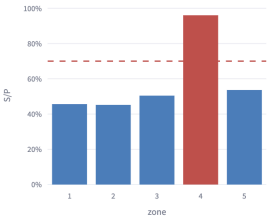


Dashboard · page Portefeuille

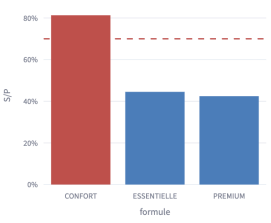
Technique et clients

Ratio sinistres sur primes par segment

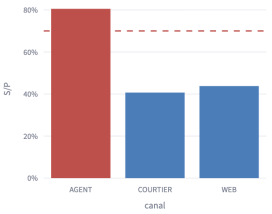
Zone 4 : S/P le plus élevé (96,0 %)
→ vérifier que la prime suit la fréquence



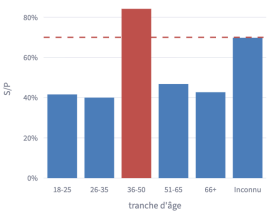
Formule CONFORT : S/P le plus élevé (81,3 %)
→ revoir sa prime et ses garanties



Canal AGENT : S/P le plus élevé (80,5 %)
→ comparer hors sinistre atypique avant d'agir



Tranche d'âge 36-50 : S/P le plus élevé (84,2 %)
→ contrôler l'adéquation du tarif



Barres rouges : S/P au-dessus du seuil d'alerte. Survolez une barre pour la fréquence, le coût moyen et la prime moyenne.

Décomposition de l'évolution du S/P

Dashboard · page Technique et clients

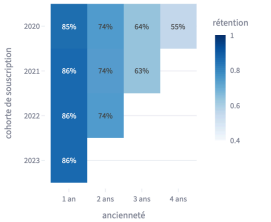
Le coût moyen explique l'essentiel des variations du S/P ; la prime moyenne est figée
→ piloter les sinistres graves et réviser les primes



Méthode LMDI : S/P = fréquence × coût moyen / prime moyenne ; la somme des effets égale la variation. L'effet du volume de contrats sur le ratio est nul par construction.

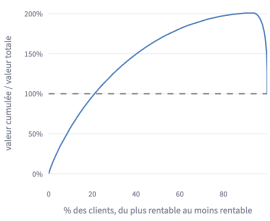
Clients

Rétention par cohorte : 14 % des contrats perdus dès la 1
→ cibler la première échéance



Seules les cellules entièrement observables au 30/06/2025 sont affichées.

Concentration de la valeur : 20 % des clients font 97% de



Valeur observée = primes acquises − sinistres payés, 2020 à juin 2025. Filtres produit et région appliqués.

Dashboard · page Technique et clients

Exploitation

État de la chaîne

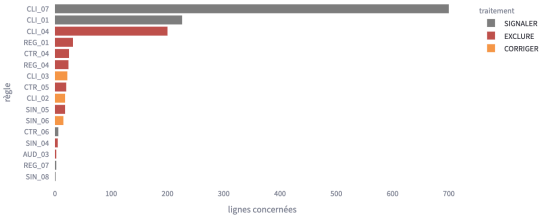
Dernier chargement	Données à jour au	Tests du dernier lancement	Anomalies bloquantes
19/10/202…	30/06/2025	56 / 56 réu…	326

Tous les tests du dernier lancement sont au vert.

source	fichiers	lignes lues	lignes chargées	rejets à l'ingestion	dernier chargement	dernier fichier
audits	1	372	372	0	2026-10-19 12:18:36	antifraude/audits.csv
clients	1	15200	15200	0	2026-10-19 12:18:36	crm/clients.csv
contrats	1	20264	20264	0	2026-10-19 12:18:36	contrats/contrats.csv
reglements	64	3207	3207	0	2026-10-19 12:18:43	reglements/reglements_2025_07.csv
sinistres	1	2805	2805	0	2026-10-19 12:18:36	sinistres/sinistres.jsonl

Lignes écartées ou signalées par règle de qualité

CLI_07 (client mineur à la date de sa première souscription) est la première anomalie : 700 lignes
→ traiter les anomalies à la source avec les services concernés



› Les 36 règles, y compris celles sans anomalie

› Résultats détaillés des tests du dernier lancement

Dashboard · page Exploitation

5.2 Orchestration et alertes

Planification.

- **Déclenchement :** `pipeline/surveiller.py` compare les fichiers du dossier source au journal d'ingestion (empreinte SHA-256). S'il trouve un fichier nouveau ou modifié, comme le fichier mensuel des règlements, il lance `make run` : ingestion, transformations, tests bloquants et publication des résultats de tests. Sinon il ne fait rien.
- **Sous macOS :** la planification (`orchestration/fr.boreal.pipeline.plist` , installée par `make planifier`) se déclenche à chaque modification des dossiers sources, ce qui correspond à l'arrivée du fichier mensuel. Elle tourne aussi chaque jour à 7 h en filet de sécurité.
- **Sous Linux :** une ligne cron équivalente est fournie (`orchestration/crontab.txt`).

Alertes. Un échec (code de retour non nul) produit trois effets :

- une ligne dans `logs/alertes.log` ;
- une notification macOS ;
- si la variable `BOREAL_WEBHOOK_ALERTE` est définie, un message JSON vers un canal Slack ou Teams.

Le journal complet de chaque exécution est conservé dans `logs/` .

Tests à chaque lancement. `dbt build` exécute 56 tests de données, et un test en échec interrompt les modèles qui en dépendent. Les résultats sont publiés dans `meta.resultats_tests` et affichés sur la page Exploitation, y compris en cas d'échec. S'y ajoutent 17 tests pytest (`make test`) :

- idempotence de l'ingestion et rechargement d'un mois ;
- exactitude de la décomposition du S/P ;
- effacement RGPD ;
- surveillance et alertes ;
- rendu des quatre pages du dashboard.

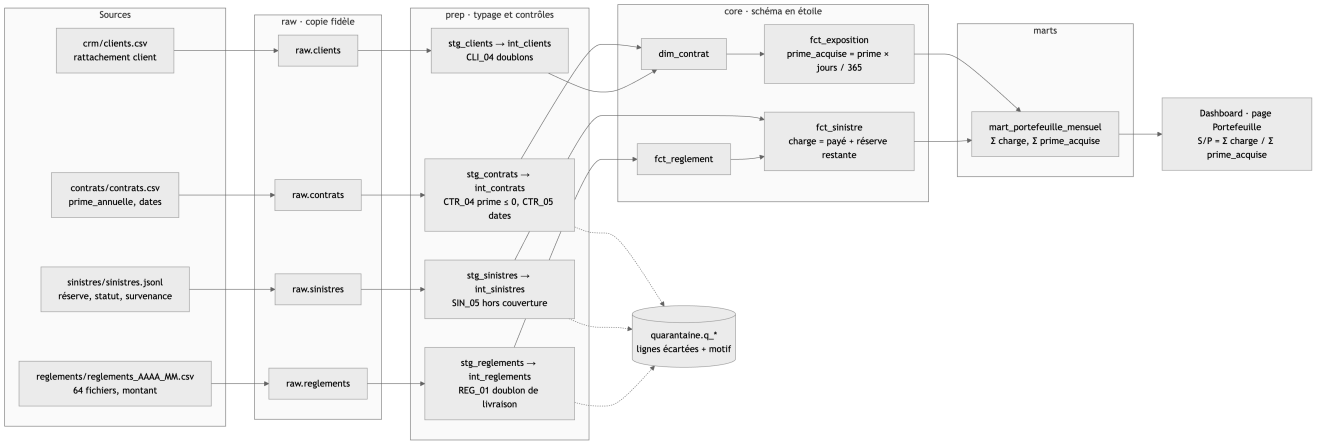
Reproductibilité. Toute la chaîne a été rejouée dans une copie vierge du dépôt, avec un environnement Python neuf : `make install` , `make sources` , `make run` puis `make test` s'exécutent de bout en bout sans erreur.

5.3 Documentation

Document	Contenu
`README.md`	Exécution en cinq commandes, commandes d'exploitation, organisation du dépôt
`docs/catalogue.md`	Catalogue des données : les 47 tables de l'entrepôt et chacune de leurs colonnes, avec type et définition. Généré par `make docs` à partir des métadonnées dbt et d'un dictionnaire unique (`dbt/dictionnaire_colonnes.yml`). La génération échoue si une colonne n'est pas définie
`dbt docs serve`	Lignage interactif de toutes les tables, de la source au mart
`docs/*.md`	Documentation de chaque livrable, reprise dans ce dossier

5.4 Lignage d'un indicateur : le ratio S/P, de la source au graphique

Exemple suivi : le **S/P annuel** affiché sur la page Portefeuille du dashboard et dans le dossier (livrable 3). Le lignage complet et interactif de toutes les tables est consultable avec `make docs` , puis `dbt docs serve` .



Étape	Objet	Transformation	Contrôle
1	`contrats.csv`, `sinistres.jsonl`, `reglements_*.csv`, `clients.csv`	Lecture, détection de l'encodage, du séparateur et des en-têtes (`pipeline/ingest.py`)	Journal d'ingestion, rejets de lecture, empreinte SHA-256
2	`raw.*`	Copie fidèle en texte, avec fichier, ligne et chargement	`ingestion_sans_echec`
3	`prep.stg_*`	Typage des dates et des montants	Colonnes illisibles repérées
4	`prep.int_*`	36 règles de qualité ; dédoublonnage des clients et des paiements	Quarantaine avec motif, `reconciliation_*`
5	`core.fct_exposition`	Prime acquise = prime annuelle × jours couverts / 365, par contrat et par année	`exposition_toujours_positive`, `exposition_egale_duree_contrat`
6	`core.fct_reglement`, `core.fct_sinistre`	Charge = règlements payés + réserve restante des dossiers ouverts	`montant_paye_egal_reglements`, `reconciliation_reglements_brut_coeur`
7	`marts.mart_portefeuille_mensuel`	Sommes par mois, produit, zone, canal et région	`mart_technique_reconcilie_coeur` (mêmes totaux que le cœur)
8	Dashboard (`dashboard/app.py`) et notebooks	S/P = Σ charge / Σ primes acquises (`analyse/indicateurs.py`, définition unique)	`tests/test_dashboard.py`

6. Protection des données personnelles (RGPD)

Analyse établie par l'équipe data. Les durées de conservation et les bases légales sont des propositions à valider avec le délégué à la protection des données (DPO) de Boréal Assurances.

6.1 Données personnelles présentes

Les sources sont **pseudonymisées** : aucun nom, aucune adresse, aucun téléphone ni aucun e-mail en clair. Les données restent pourtant **personnelles** au sens du RGPD (considérant 26) : Boréal détient dans son CRM la correspondance entre les identifiants et les personnes, et le croisement de plusieurs attributs peut suffire à isoler un individu.

Donnée	Où	Nature	Sensibilité
`client_id`	Toutes les couches	Identifiant pseudonyme	Rattache toutes les autres données à une personne
`email_hash`	raw, prep, core, snapshots, quarantaine	Empreinte de l'e-mail	Pseudonyme. Une empreinte sans sel peut être retrouvée par essai d'adresses connues
`date_naissance`	raw, prep, core, snapshots	Donnée d'identification	Combinée à la région, elle réduit fortement l'anonymat
`region` , `csp`	raw, prep, core, snapshots, marts (`mart_clients` , `mart_technique`)	Profil socio-démographique	Modérée
`consent_marketing`	raw, prep, core, snapshots	Choix de la personne	Conditionne tout usage commercial
Contrats (prime, bonus-malus, puissance, surface, zone)	raw, prep, core, marts	Données contractuelles liées à une personne	Modérée
Sinistres et règlements	raw, prep, core, marts	Événements de la vie de l'assuré	Modérée à forte selon le sinistre
Audits (`fraude_confirmee`)	raw, prep, core, marts	Soupçon ou constat de fraude	**Forte** : données relatives à des infractions potentielles (article 10), à accès très restreint

Ce qui n'en contient pas :

- **Journal et tests :** `meta.journal_ingestion` , `meta.resultats_tests` et `qualite.*` ne décrivent que des fichiers et des volumes.
- **Registre des effacements :** `meta.effacements` ne conserve que des identifiants techniques.
- **Dashboard :** il n'affiche que des agrégats. La page Technique et clients calcule la courbe de valeur client à partir de `mart_clients` , sans afficher aucune ligne individuelle.

Volumes. 15 000 clients conservés dans le cœur, dont 10 348 ayant consenti à la prospection.

6.2 Pseudonymisation et minimisation

Mesure	État
Absence d'identité directe (nom, coordonnées)	Respectée dès la source
Identifiants techniques à la place des personnes	Respectée (`client_id` , `contrat_id` , `sinistre_id`)
E-mail remplacé par une empreinte	Respectée. **Recommandation :** utiliser une empreinte salée (HMAC), dont la clé est détenue par le DPO, pour empêcher la recherche par essai d'adresses
Exactitude (article 5.1.d)	Les 200 fiches clients en double sont rapprochées (`core.client_rapprochement`). Les dates de naissance impossibles sont neutralisées (règles CLI_02 et CLI_03)

Mesure	État
Minimisation de la restitution	Les analyses et le dashboard travaillent sur des agrégats (marts). Les tables détaillées (`raw` , `prep` , `core`) sont réservées à l'équipe data
Accès	Entrepôt local (fichier DuckDB). En production : chiffrement du disque, droits d'accès par schéma, audits restreints à l'équipe antifraude

6.3 Bases légales et finalités

Finalité	Base légale proposée
Gestion des contrats et des sinistres	Exécution du contrat (article 6.1.b)
Conservation des pièces comptables et contractuelles	Obligation légale (article 6.1.c)
Pilotage technique du portefeuille (tarification, S/P, rétention)	Intérêt légitime de l'assureur (article 6.1.f). Les analyses sont agrégées
Lutte contre la fraude	Intérêt légitime (article 6.1.f), dans le cadre du référentiel de la CNIL sur la lutte contre la fraude
Prospection commerciale	**Consentement** (article 6.1.a) : seuls les clients `consent_marketing = 1` peuvent être ciblés. La segmentation de la valeur client (livrable 4) ne doit pas servir à une campagne sans ce filtre

6.4 Durées de conservation proposées

Données	Durée proposée	Fondement (à valider par le DPO)
Clients et contrats	Durée du contrat + 2 ans après sa fin, puis anonymisation	Prescription biennale des actions dérivant du contrat d'assurance (article L114-1 du Code des assurances)
Sinistres corporels (RC)	Jusqu'à 10 ans après la consolidation	Prescription des dommages corporels
Règlements (pièces comptables)	10 ans	Conservation des pièces comptables (article L123-22 du Code de commerce)
Audits concluant à une fraude	5 ans après la clôture du dossier de fraude	Référentiel CNIL de lutte contre la fraude
Audits sans fraude confirmée	Suppression rapide (ex. 6 mois)	Une suspicion non confirmée ne doit pas suivre l'assuré
Consentement à la prospection	Jusqu'au retrait, ou 3 ans sans contact	Recommandations CNIL sur la prospection
Journal d'ingestion et résultats de tests	2 ans	Traçabilité technique, sans donnée personnelle
Fichiers sources livrés (`data/sources`)	Jusqu'au chargement validé, puis archivage chiffré limité à la reprise sur incident	Minimisation

Mise en œuvre. Une tâche annuelle appliquerait ces durées en appelant la procédure d'effacement (§ 5) sur les clients dont la relation est éteinte depuis plus de 2 ans. La base `date_resiliation` le permet.

6.5 Droit à l'effacement dans chaque couche

Procédure : `make effacer CLIENT=<identifiant>` , code dans `pipeline/effacer_client.py` . Elle est testée par `tests/test_effacement.py` .

Effacement partiel, et pourquoi. Les contrats, sinistres et règlements sont **conservés** : ils relèvent d'obligations légales et de la défense de droits en justice (article 17.3.b et 17.3.e). Ce sont les attributs personnels qui sont effacés : date de naissance, région, CSP, consentement et empreinte d'e-mail. Le client devient un identifiant technique sans attribut. Les fiches doublons qui partagent son empreinte sont effacées avec lui.

Couche	Effet de l'effacement	Mécanisme
Fichiers sources (`data/sources`)	**Hors du périmètre de l'entrepôt** : le CRM de Boréal doit effacer la personne à la source. La prochaine livraison ne la contiendra plus	Procédure CRM
Brut (`raw.clients`)	Attributs personnels vidés	Mise à jour immédiate, et **réappliquée à chaque rechargement du CRM** à partir de `meta.effacements` . Un ancien fichier rechargé ne fait donc pas réapparaître les données
Registre (`meta.effacements`)	Conserve l'identifiant, l'identifiant conservé, la date et le motif, **sans** donnée personnelle	Preuve de traitement de la demande
Préparation, quarantaine, cœur, marts	Attributs vides, client marqué `est_efface` ; tranche d'âge « Inconnu »	Reconstruction par dbt (`make build` , lancé par `make effacer`)
Historique (`snapshots.snap_clients`)	Toutes les versions passées du client supprimées	Suppression explicite (le snapshot n'est pas reconstructible)
Notebooks et dossier	Uniquement des agrégats : effet négligeable	Réexécution `make notebooks`
Sauvegardes	Les données effacées disparaissent au terme du cycle de rotation des sauvegardes. Elles ne doivent pas être restaurées sans réappliquer `meta.effacements`	Procédure d'exploitation

Ce que vérifie le test automatique (`tests/test_effacement.py`) :

- les attributs du client et de son doublon sont vidés dans la couche brute et dans `core.dim_client` ;
- ses contrats sont conservés ;
- le nombre de clients du cœur reste de 15 000, car le doublon reste rattaché au client conservé ;
- un rechargement forcé du CRM ne fait pas réapparaître les données.

Conclusion

Ce que la chaîne de données apporte

Une source unique de vérité. Boréal dispose désormais d'un entrepôt qui charge automatiquement les cinq sources, détecte et met en quarantaine les anomalies avec leur motif, et réconcilie chaque chiffre avec les fichiers d'origine au centime près :

- 36 règles de qualité contrôlent les données ;
- 325 lignes sont en quarantaine ;
- 200 clients en double ont été rapprochés ;
- 32 paiements livrés deux fois ont été écartés.

Le ratio S/P n'a plus qu'une définition, partagée par le dossier et le tableau de bord.

Ce que disent les données

1. **L'habitation est sous-tarifée.**
   - Son S/P est de 64 %, contre 38 % pour l'auto hors sinistre atypique.
   - En zone 5, la fréquence double alors que la prime n'augmente que de 32 %.
   - Les primes n'ont pas évolué depuis 2020.
2. **Le résultat dépend de quelques sinistres graves.** Un dossier représente 22 % de la charge de la période, et 10 % des sinistres en représentent 61 %.
3. **Fidélité et gestion :**
   - 14 % des contrats sont perdus dès la première année ;

- les clients Web résilient 1,5 fois plus que ceux des agences ;
- le multi-équipement retient les clients par l'addition des contrats, pas par une meilleure fidélité de chacun ;
- les délais de premier règlement sont homogènes, autour de 50 jours ;
- les audits ciblent les mauvais dossiers et interviennent après le paiement : 407 000 € versés sur des fraudes confirmées.

Limites

- **Années récentes provisoires.**
  - 2025 n'est observée que sur six mois, et 36 % de sa charge est en réserve.
  - Les sinistres survenus mais pas encore déclarés sont inconnus : les S/P 2024 et 2025 sont des minima.
- **Données absentes des sources.**
  - Pas de frais : le S/P n'est pas une marge, et le seuil d'alerte reste une hypothèse.
  - Pas de date de clôture : le dernier règlement en tient lieu.
  - Pas d'historique des attributs clients, constitué à partir de maintenant par un snapshot.
- **Défauts de la source.** Les âges du CRM paraissent plafonnés à 18 ans à la date d'extraction : environ 700 clients auraient été mineurs à leur souscription.
- **Portée des taux de fraude.** Les audits ne portent que sur des dossiers choisis : les taux de fraude ne s'appliquent qu'à cette population.
- **Nature de l'étude.** L'analyse est descriptive et explicative. Elle n'établit pas de causalité et ne prévoit pas l'avenir.

Annexes

Les commandes pour reproduire les résultats figurent au chapitre 5 et dans le `README.md` du dépôt (`make install` , `make sources` , `make run` , `make test` , `make dashboard` ; ce dossier : `make dossier`).

A. Origine des chiffres clés

Chiffre	Valeur	Produit par
Lignes et paiements distincts des règlements	3 207 / 3 175	Requête du chapitre 1 sur `raw.reglements`
Volume de chaque règle de qualité	36 règles	Table `qualite.bilan_regles` (modèle `dbt/models/qualite/bilan_regles.sql`)
Réconciliation des règlements	11 176 660,34 € + 118 175,46 € = 11 294 835,80 €	Test `reconciliation_reglements_brut_coeur`
Taux de doublons clients	1,32 %	Requête du chapitre 2 ; table `core.client_rapprochement`
Exposition et primes acquises par année	45 215 années-police, 20,0 M€	Requête du chapitre 2 sur `core.fct_exposition`
Indicateurs par axe, décomposition du S/P, intervalles de confiance, tests, queue des coûts	Chapitre 3	Notebook L3 : § 1 (`tableau([...])`), § 2 (`decomposer_sp`), § 3 (cellules IC, Test 1, Test 2, queue de distribution)
Rétention, multi-détention, valeur client	Chapitre 4, § 1 et 2	Notebook L4, § 1 et 2 ; marts `mart_retention_contrats` , `mart_retention_clients` , `mart_clients`
Délais et audits	Chapitre 4, § 3 et 4	Notebook L4, § 3 et 4 ; mart `mart_sinistres`